


Introducción a los métodos estadísticos

bayesianos en Ecología

Pablo Inchausti

Programa del curso:

1. Introducción general
2. Elementos básicos del análisis bayesiano
3. Análisis bayesiano I
4. Análisis bayesiano II
5. Modelos bayesianos jerárquicos



2. Elementos básicos del análisis bayesiano

Teórico 02

- a. Modelo Lineal General: regresión múltiple.
- b. Distribuciones previas I:
- c. GLM en 6 dispositivas.

a. Modelo Lineal General: regresión múltiple.

El Modelo Lineal General supone que $Y \sim \text{Normal}(\mu_Y, \sigma_Y)$ y que μ_Y tiene relación lineal con vars. explicativas categóricas y/o numéricas. μ_Y y σ_Y son independientes.

Forma general de proceder: 1) distr. de var de respuesta, 2) relaciones entre var respuesta y explicativa(s), 3) formular modelo y las dist previas, 4) ajustar el modelo, 5) evaluar la calidad del ajuste, 6) curvas condicionales.



Hagamos un 1er análisis bayesiano de regresión múltiple.

Los datos: SO_2 en 42 ciudades de USA en función de vars. explicativas numéricas (clima e industria).

```
> DF1= read.csv("Teo 02 regr multiple.csv", header=T)
> summary(DF1)
```

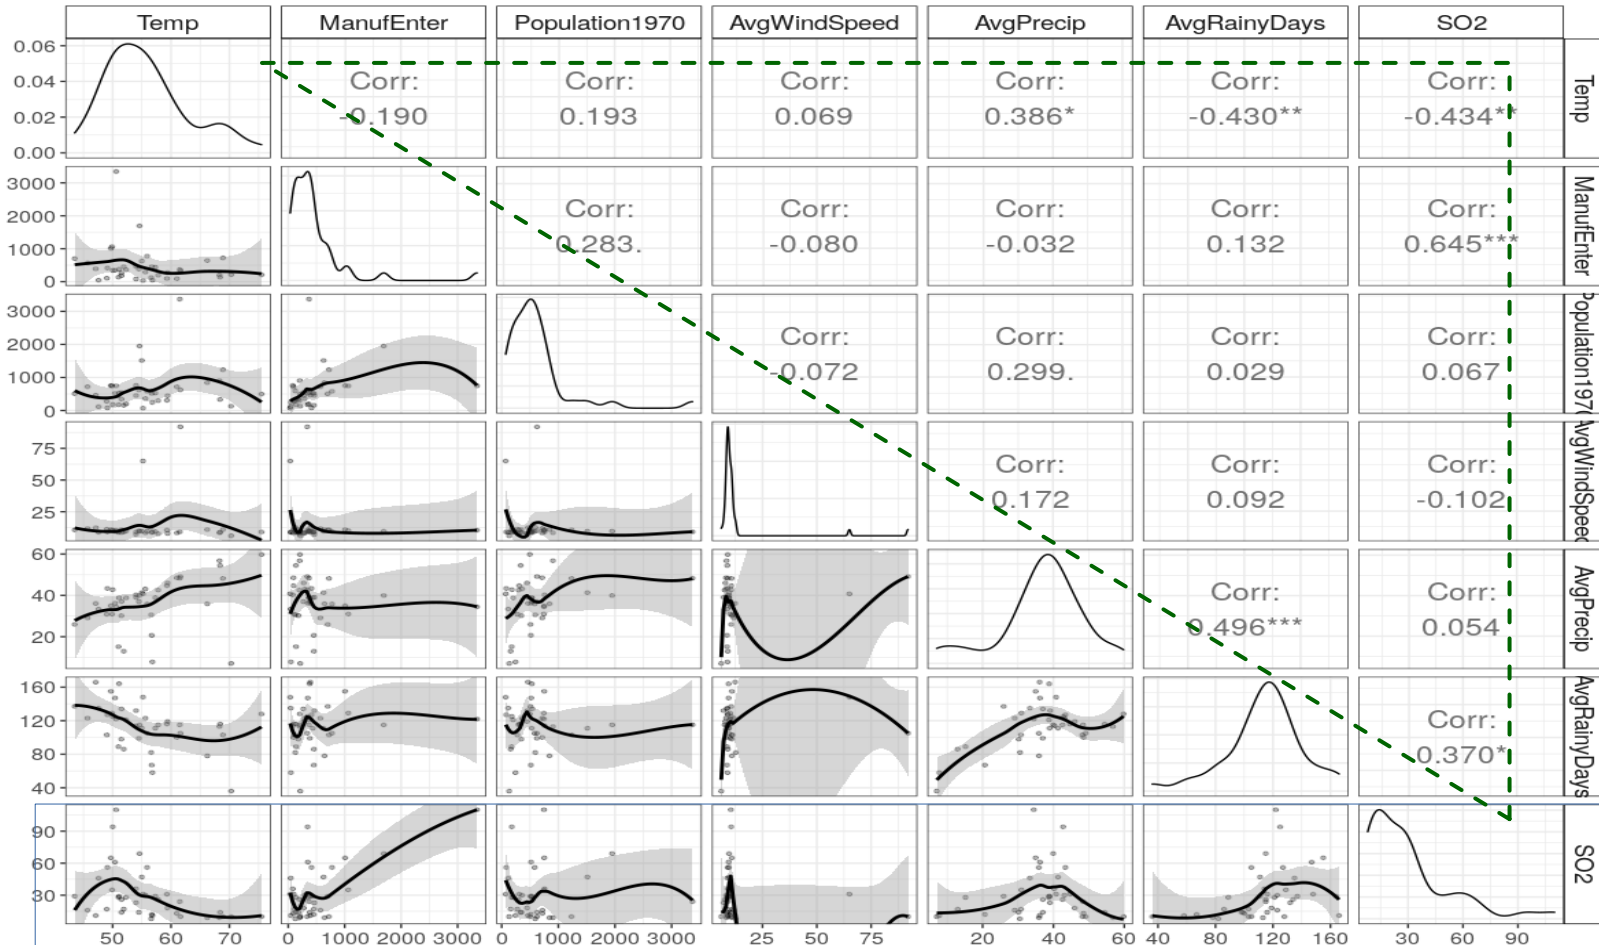
City	SO2	Temp	ManufEnter	Population1970	AvgWindSpeed	AvgPrecip	AvgRainyDays
Albany : 1	Min. : 8	Min. :43.5	Min. : 35	Min. : 71	Min. : 6.0	Min. : 7.0	Min. : 36
Albuquerque: 1	1st Qu.: 13	1st Qu.:50.6	1st Qu.: 181	1st Qu.: 299	1st Qu.: 8.8	1st Qu.:31.0	1st Qu.:103
Atlanta : 1	Median : 26	Median :54.6	Median : 347	Median : 515	Median : 9.4	Median :38.7	Median :115
Baltimore : 1	Mean : 30	Mean :55.8	Mean : 463	Mean : 609	Mean :12.9	Mean :36.8	Mean :114
Buffalo : 1	3rd Qu.: 35	3rd Qu.:59.3	3rd Qu.: 462	3rd Qu.: 717	3rd Qu.:10.6	3rd Qu.:43.1	3rd Qu.:128
Charleston : 1	Max. :110	Max. :75.5	Max. :3344	Max. :3369	Max. :92.0	Max. :59.8	Max. :166

1) Distr. de var de respuesta: → Likelihood del modelo



```
require(fitdistrplus)
norm.m2=fitdist(DF1$SO2,"norm")
lognorm.m2=fitdist(DF1$SO2,"lnorm")
cdf.m2=cdfcomp(list(norm.m2,lognorm.m2),
  xlogscale=T, plotstyle ="ggplot")+etc
qq.m2=qqcomp(list(norm.m2,lognorm.m2),
  plotstyle ="ggplot")+etc
grid.arrange(cdf.m2, qq.m2, ncol=2)
```

2) Relaciones entre var respuesta y explicativa(s)



ggpairs(Df1[,c("Temp", "ManufEnter", "Population1970",
 "AvgWindSpeed", "AvgPrecip", "AvgRainyDays", "SO2")],
 lower=list(continuous = wrap("smooth_loess", alpha =
 0.3, size=1)), upper = list(continuous = wrap("cor",
 size=6))) + etc

3) Modelo estadístico y distr previas:

$Y \sim \text{Lognormal}$, pero hagamos $\log Y \sim \text{Normal}$.

$\text{DF1}\$\log\text{SO2} = \log(\text{DF1}\$\text{SO2})$ $\log\text{SO2} \sim \text{Normal}(\mu_Y, \sigma_Y)$

$\mu_Y = \beta_0 + \beta_1 X_1 + \dots + \beta_6 X_6$: 7 parámetros + σ_Y

8 distr previas
a especificar

Estandarizar las vars explicativas a media=0, sd=1.

```
> DF1s=scale(DF1[,c("Temp", "ManufEnter", "Population1970", "AvgWindSpeed", "AvgPrecip", "AvgRainyDays")], center=T, scale=T)
> summary(DF1s)
```

Temp	ManufEnter	Population1970	AvgWindSpeed	AvgPrecip	AvgRainyDays
Min. : -1.697	Min. : -0.76	Min. : -0.93	Min. : -0.45	Min. : -2.525	Min. : -2.939
1st Qu.: -0.714	1st Qu.: -0.50	1st Qu.: -0.53	1st Qu.: -0.27	1st Qu.: -0.493	1st Qu.: -0.411
Median : -0.161	Median : -0.21	Median : -0.16	Median : -0.23	Median : 0.167	Median : 0.041
Mean : 0.000	Mean : 0.00	Mean : 0.00	Mean : 0.00	Mean : 0.000	Mean : 0.000
3rd Qu.: 0.489	3rd Qu.: 0.00	3rd Qu.: 0.19	3rd Qu.: -0.15	3rd Qu.: 0.539	3rd Qu.: 0.532
Max. : 2.731	Max. : 5.11	Max. : 4.77	Max. : 5.14	Max. : 1.956	Max. : 1.965

```
> DF1s=as.data.frame(cbind(logSO2=DF1$logSO2, DF1s))
```

Permite **comparar los efectos relativos** de cada var explicativa, y el **intercepto es ahora interpretable**.

```
> get_prior(formula=logS02~Temp+ManufEnter+Population1970+AvgWindSpeed+AvgPrecip+AvgRainyDays,
+           data=DF1s,family=gaussian)
```


prior	class	coef	group	resp	dpar	nlpar	lb	ub	source
(flat)	b								default
(flat)	b	AvgPrecip							(vectorized)
(flat)	b	AvgRainyDays							(vectorized)
(flat)	b	AvgWindSpeed							(vectorized)
(flat)	b	ManufEnter							(vectorized)
(flat)	b	Population1970							(vectorized)
(flat)	b	Temp							(vectorized)
student_t(3, 3.3, 2.5)	Intercept								default
student_t(3, 0, 2.5)	sigma						0		default

Útil para ver las
previas a especificar

brms: por defecto “previas débilmente informativas”

Paciencia
y Calma

Ello implica que en **brms** se podría ajustar un modelo sin especificar las distr previas.



No hay razón para renunciar al aspecto clave (pero siempre debatido y discutido) de la inferencia bayesiana.

El comando `set_prior` permite especificar dist previas para todas `set_prior("normal(0, 2)", class = "b")` las pendientes o para cada una `set_prior("normal(0,1)", class = "b", coef = "Temp")` por separado.

Las dist previas se definen ANTES Y SIN ver los datos.




Reflejan el conocimiento previo acumulado del problema bajo estudio reflejado en el conjunto de valores plausibles de los parámetros de un modelo estadístico a ajustar.

Definí `set_prior("normal(0, 2)", class = "intercept")` → 95% de los valores de `logSO2` estarán en $[-4; 4] \rightarrow [-\exp(4) = 0.183; \exp(4) = 54.6]$, ¿un amplio intervalo?

Definí `set_prior("normal(0, 2)", class = "b")` → 95% de los valores de las pendientes (estandarizadas) estarán en $[-2; 2]$.

efectos pueden ser positivos o negativos...

Definí `set_prior("cauchy(0, 3)", class = "sigma")` → como $\sigma_Y > 0$, se usa “half Cauchy”. **IMPORTANTE GRAFICAR PREVIAS**





```
int.m2=ggplot(data.frame(x = c(-4, 4)), aes(x)) +  
  stat_function(fun = dnorm, n = 1000, args = list(mean=0, sd=2)) + etc  
slope.m2=ggplot(data.frame(x = c(-2, 2)), aes(x)) +  
  stat_function(fun = dnorm, n = 1000, args = list(mean=0, sd=1)) + etc  
sd.m2=ggplot(data.frame(x = c(0, 5)), aes(x)) +  
  stat_function(fun = dcauchy, n = 1000, args = list(location=0, scale=3)) + etc  
plot_grid(int.m2, slope.m2, sd.m2, ncol=3, labels = LETTERS[1:3],  
  align="hv", label_x=0.90, label_y=0.95)  
prior.m2 = c(set_prior("normal(0, 2)", class = "Intercept"),  
  set_prior("normal(0, 1)", class = "b"),  
  set_prior("cauchy(0,3)", class = "sigma"))  
m2.brms=brm(formula=logSO2~Temp+ManufEnter+Population1970+  
AvgWindSpeed+AvgPrecip+AvgRainyDays, data=DF1s, family=gaussian, prior =  
prior.m2, warmup = 1000, chains=3, iter=2000, thin=3, future=T)
```

$(2000-1000)*3 \text{ cad}=1000$
 $\text{thin}=3$ valores

← Las distr previas:

Se generarán 3 cadenas (de Markov) de 2000 iteraciones, descartándose las 1eras 1000 de cada una, y reteniendo 1 de cada 3 valores en cada cadena.

4) Ajustar el modelo.

```
> summary(m2.brms)
```

```
Family: gaussian
```

```
Links: mu = identity; sigma = identity
```

```
Formula: logS02 ~ Temp + ManufEnter + Population1970 + AvgWindSpeed + AvgPr
```

```
Data: DF1s (Number of observations: 41)
```

```
Draws: 3 chains, each with iter = 2000; warmup = 1000; thin = 3;  
total post-warmup draws = 1000
```

Population-Level Effects:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
Intercept	3.15	0.08	2.98	3.30	1.00	927	1039
Temp	-0.34	0.14	-0.62	-0.07	1.00	998	789
ManufEnter	0.27	0.10	0.06	0.45	1.00	1015	990
Population1970	-0.03	0.10	-0.22	0.16	1.00	960	955
AvgWindSpeed	-0.08	0.09	-0.26	0.09	1.00	960	945
AvgPrecip	0.15	0.15	-0.14	0.43	1.00	945	920
AvgRainyDays	0.09	0.15	-0.19	0.37	1.00	981	856

Family Specific Parameters:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
sigma	0.54	0.07	0.43	0.71	1.00	980	938

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS and Tail_ESS are effective sample size measures, and Rhat is the potential scale reduction factor on split chains (at convergence, Rhat = 1).

Una distr posterior de 8
dimensiones
(parámetros)



Estadísticos de
las distr. marginales
de cada parámetro.



media, sd, cuantiles
2.5 y 97.5% (Int
Credibilidad 95%).

```
> summary(m2.brms)
```

Population-Level Effects:

	Rhat	Bulk_ESS	Tail_ESS
Intercept	1.00	927	1039
Temp	1.00	998	789
ManufEnter	1.00	1015	990
Population1970	1.00	960	955
AvgWindSpeed	1.00	960	945
AvgPrecip	1.00	945	920
AvgRainyDays	1.00	981	856

Family Specific Parameters:

	Rhat	Bulk_ESS	Tail_ESS
sigma	1.00	980	938

Convergencia de las cadenas:

$$R = \sqrt{\frac{\text{Var}_{\text{Within}} + \frac{1}{\text{iter}} (\text{Var}_{\text{Betw}} - \text{Var}_{\text{Within}})}{\text{Var}_{\text{Within}}}} \quad 1 < R < 1.1 \rightarrow \text{OK}$$

$$\text{ESS} = \frac{\text{iter}}{1 + 2 \sum \rho_i} \quad \text{ESS} \sim 1000 \rightarrow \text{OK}$$

Opciones: aumentar iter y/o thin

Las 3 cadenas deben converger a la misma distr. posterior estacionaria y tener muchos estimados de los parámetros con baja (ej. $< |0.143|$) autocorrelación.

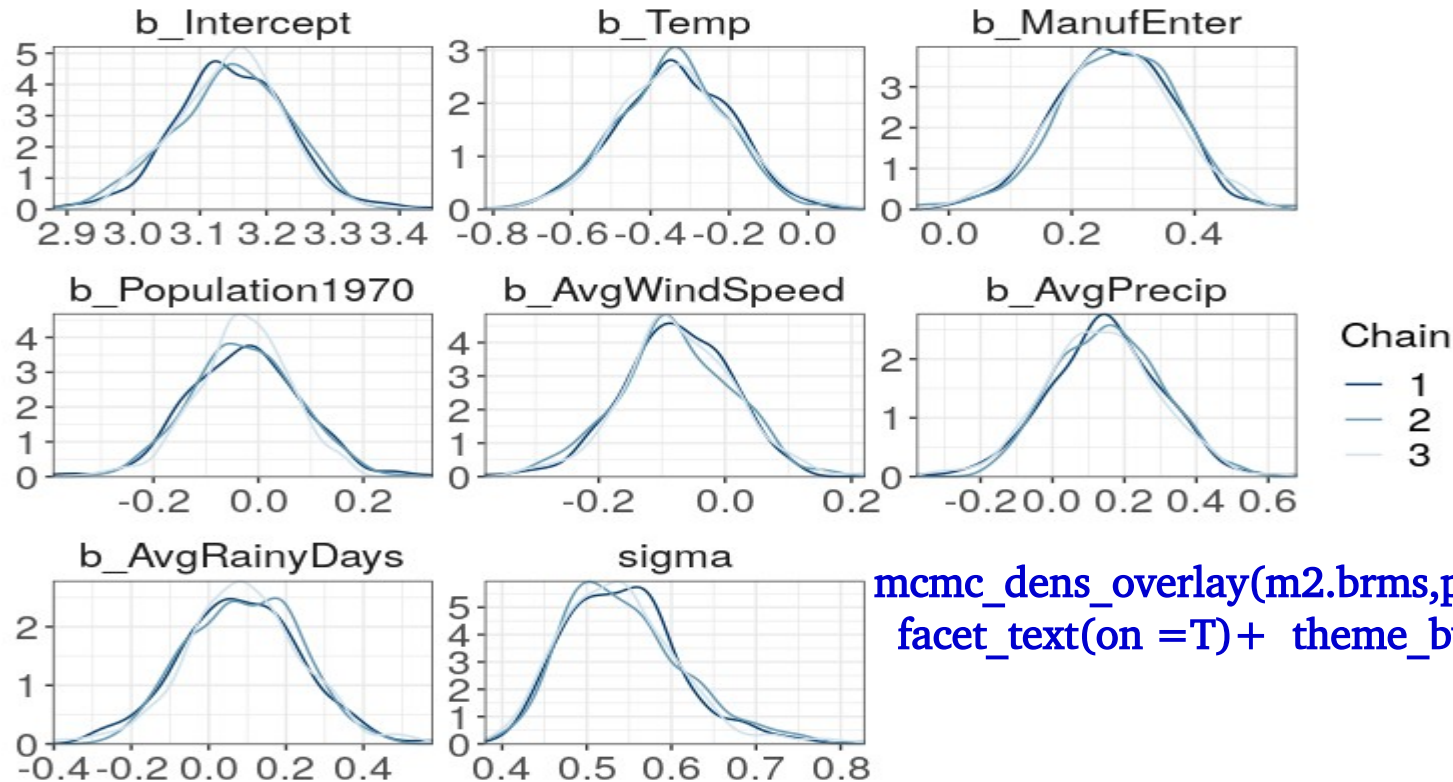
→ verificación de convergencia del algoritmo es necesaria para fusionar las 3 cadenas empleadas.

GRÁFICOS

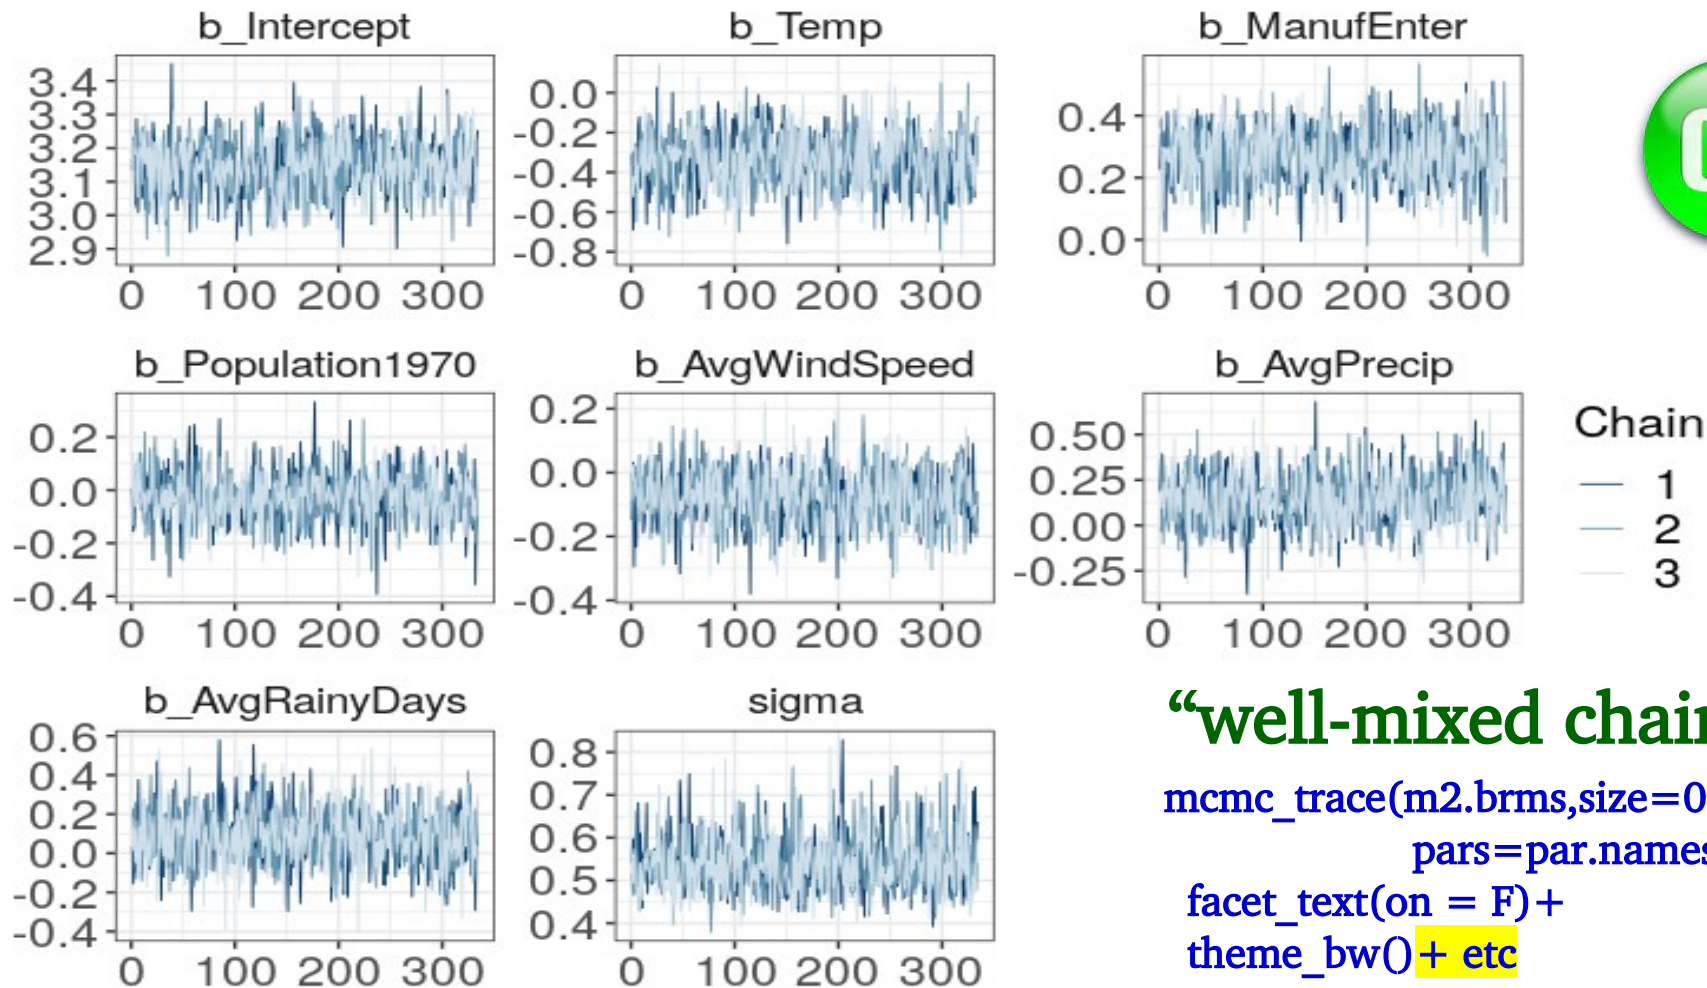
```
> variables(m2.brms)
```

```
[1] "b_Intercept"      "b_Temp"            "b_ManufEnter"      "b_Population1970"  "b_AvgWindSpeed"  
[6] "b_AvgPrecip"      "b_AvgRainyDays"    "sigma"              
```

```
par.names.m2=variables(m2.brms)[1:length(variables(m2.brms))-2]
```

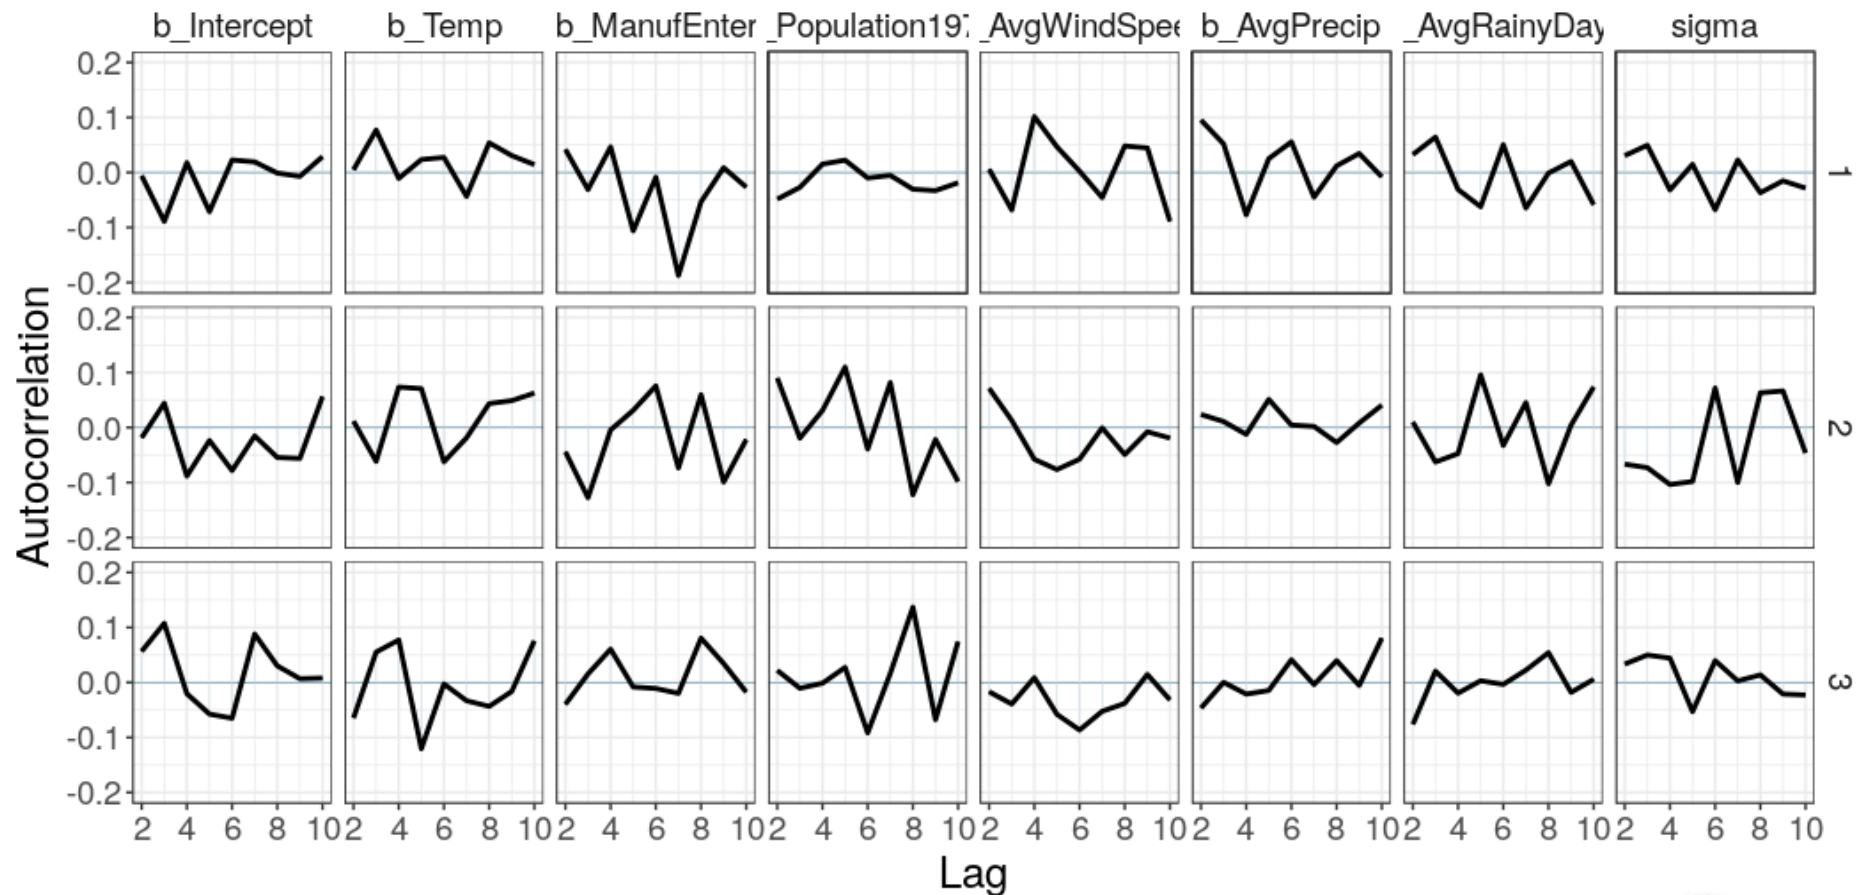


```
mcmc_dens_overlay(m2.brms,pars=par.names.m2)+  
facet_text(on =T)+ theme_bw()+ etc
```



“well-mixed chains”

```
mcmc_trace(m2.brms,size=0.3,
            pars=par.names.m2)+
facet_text(on = F)+
theme_bw() + etc
```

`mcmc_acf(m2.brms, pars=par.names.m2)+ scale_x_continuous(limits=c(2,10))+
scale_y_continuous(limits=c(-0.2,0.2)) + etc`



Exploremos un poco más la convergencia de las cadenas:

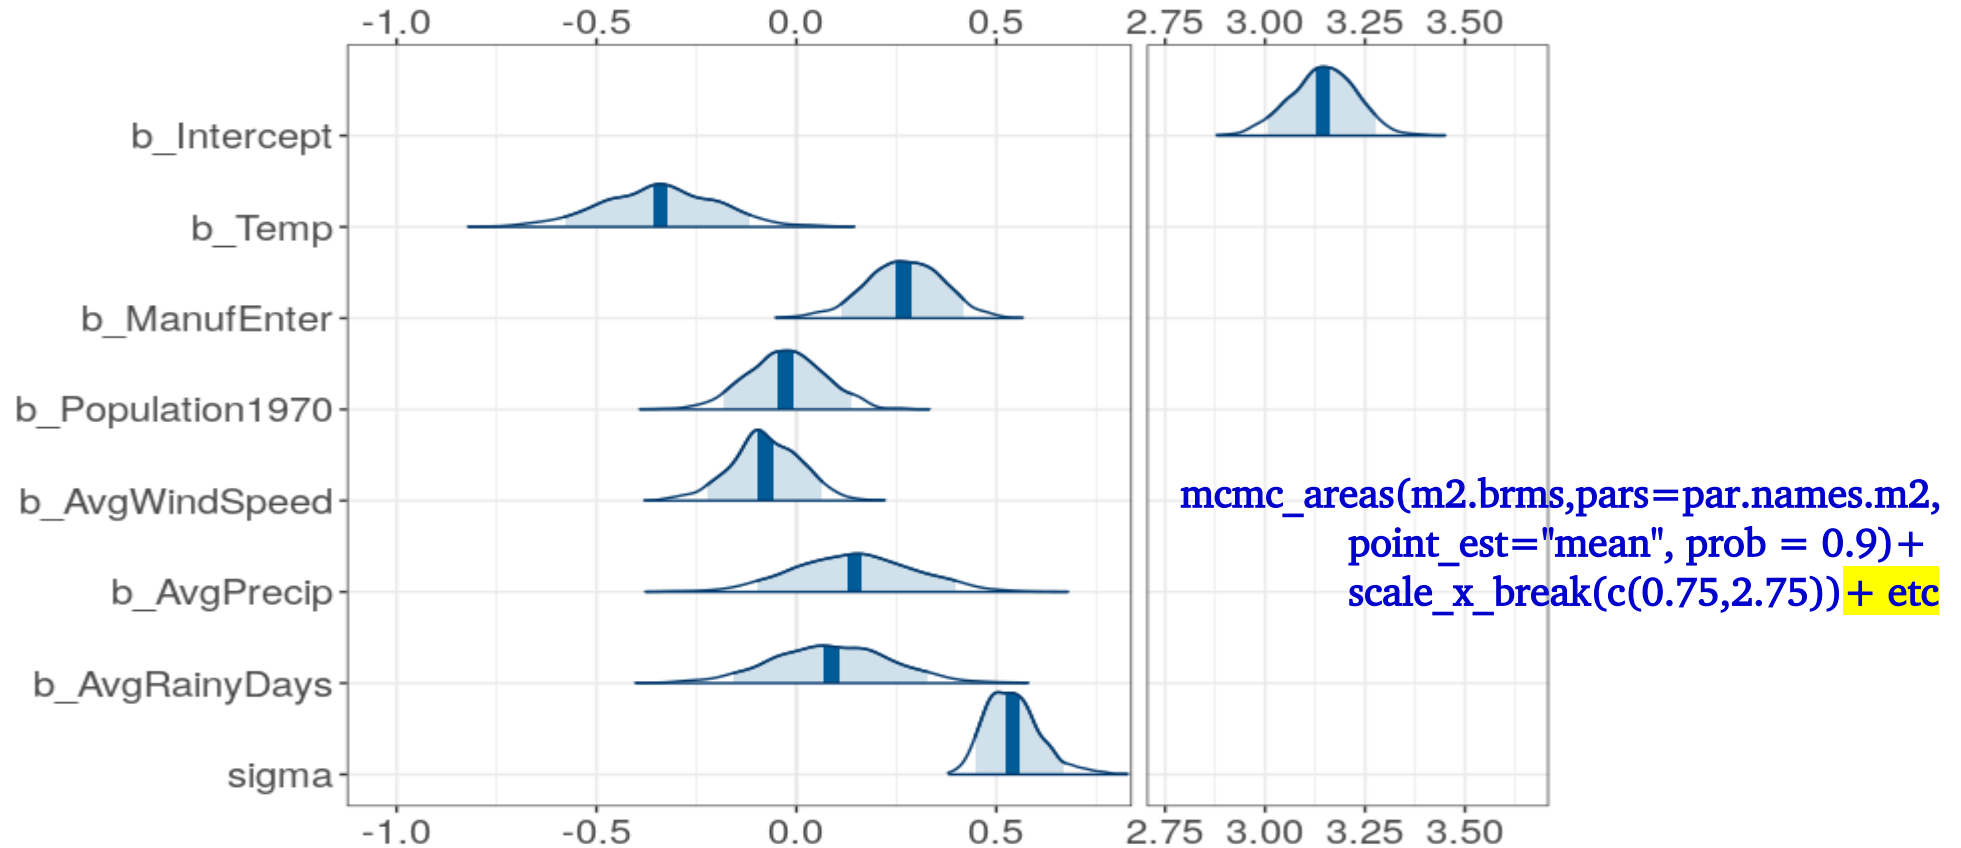
```
> dist.post.m2=as_draws_df(m2.brms,pars=pars.m2.brms, add_chain = F)
> names(dist.post.m2)
[1] "b_Intercept"      "b_Temp"           "b_ManufEnter"      "b_Population1970"  "b_AvgWindSpeed"
[6] "b_AvgPrecip"       "b_AvgRainyDays"   "sigma"              "lprior"            "lp__"
[11] ".chain"           ".iteration"        ".draw"

> summaryBy(b_Intercept+b_Temp+b_ManufEnter+b_Population1970+b_AvgWindSpeed+b_AvgPrecip+
+           b_AvgRainyDays+sigma~.chain, FUN=c(mean), data=dist.post.m2)
# A tibble: 3 × 9
  .chain b_Intercept.mean b_Temp.mean b_ManufEnter.mean b_Population1970.mean b_AvgWindSpeed.mean b_AvgPrecip.mean b_AvgRainyDays.mean sigma.mean
  <int>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>
1     1      3.15      -0.339      0.268      -0.0265     -0.0777      0.146      0.0828      0.543
2     2      3.15      -0.349      0.274      -0.0259     -0.0792      0.156      0.0922      0.544
3     3      3.14      -0.337      0.266      -0.0286     -0.0726      0.135      0.0903      0.538

> summaryBy(b_Intercept+b_Temp+b_ManufEnter+b_Population1970+b_AvgWindSpeed+b_AvgPrecip+
+           b_AvgRainyDays+sigma~.chain, FUN=sd, data=dist.post.m2)
# A tibble: 3 × 9
  .chain b_Intercept.sd b_Temp.sd b_ManufEnter.sd b_Population1970.sd b_AvgWindSpeed.sd b_AvgPrecip.sd b_AvgRainyDays.sd sigma.sd
  <int>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>
1     1      0.0842      0.143      0.0921      0.106      0.0839      0.155      0.154      0.0674
2     2      0.0855      0.140      0.0973      0.0988      0.0909      0.144      0.141      0.0706
3     3      0.0784      0.148      0.0968      0.0876      0.0885      0.156      0.152      0.0687
```

No es necesario hacer esto cada vez...

Distribuciones posteriores de los parámetros:



Gelman et al (2018)
propusieron un métrico:

$$R^2 = \frac{\text{Variance}(Y_{\text{fitted}})}{\text{Variance}(Y_{\text{fitted}}) + \text{Variance}(Y_{\text{residuals}})}$$

Obtenida de la **distr predictiva posterior** (que explicaré luego)

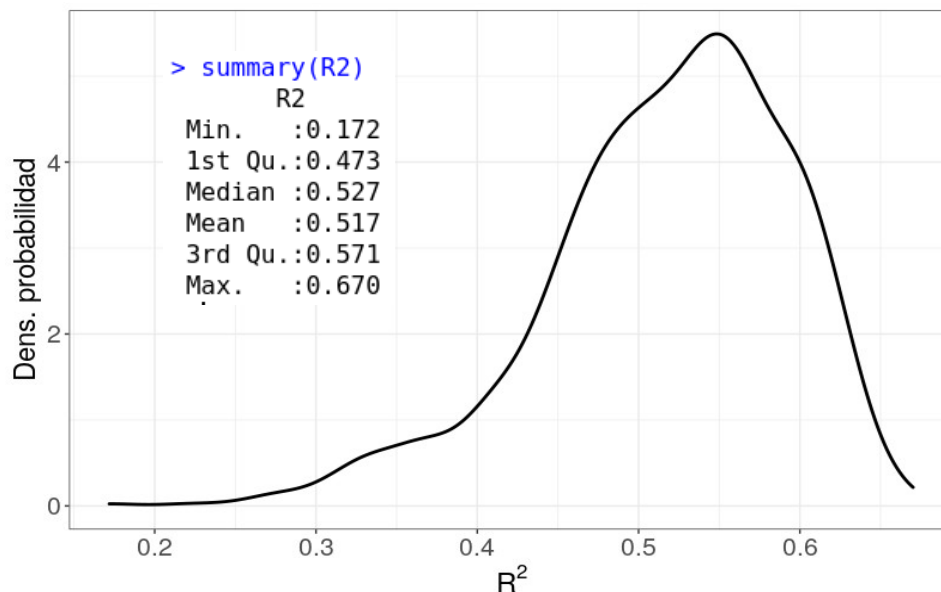
```
> str(posterior_predict(m2.brms))
num [1:1002, 1:41] 2.258 0.745 2.519 1.479 1.996
- attr(*, "dimnames")=List of 2
  ..
```

```
> str(DF1)
'data.frame': 41 obs. of 8 variables:
```

```
R2=data.frame(R2=bayes_R2(m2.brms,
                           summary=F))
```

```
ggplot(data=R2, aes(x=R2))+
  geom_density(size=1)+
  labs(x=expression(paste("R" ^ 2)),
       y="Dens. probabilidad")+etc
```

```
> bayes_R2(m2.brms)
  Estimate Est.Error  Q2.5 Q97.5
R2      0.517      0.076 0.335 0.632
```



5) Evaluar la calidad del ajuste

Análisis de residuos y posterior predictive checks (luego)

```
res.m2.brms=as.data.frame(residuals(m2.brms, type="pearson", ndraws=1000, summary=T))
```

```
> str(res.m2.brms)
```

```
'data.frame': 41 obs. of 4 variables:
 $ Estimate : num 0.825 -0.463 -0.482 -0.247 0.723
 $ Est.Error: num 0.58 0.309 0.329 0.349 0.349 ...
 $ Q2.5 : num -0.3249 -1.0494 -1.1397 -0.9378 0.723
 $ Q97.5 : num 1.984 0.144 0.161 0.469 1.42 ...
```

```
> head(fit.m2.brms,2)
```

	Estimate	Est.Error	Q2.5	Q97.5
1	1.77	0.377	1.01	2.51
2	2.84	0.182	2.48	3.18

```
fit.m2.brms=as.data.frame(fitted(m2.brms, scale="linear", summary=T, ndraws=1000))
```

Poniendo todo en DF1s para hacer los gráficos:

```
DF1s$resid=res.m2.brms$Estimate
```

```
DF1s$resid.Q2.5=res.m2.brms$Q2.5
```

```
DF1s$resid.Q97.5=res.m2.brms$Q97.5
```

```
DF1s$fit=fit.m2.brms$Estimate
```

```
DF1s$fit.Q2.5=fit.m2.brms$Q2.5
```


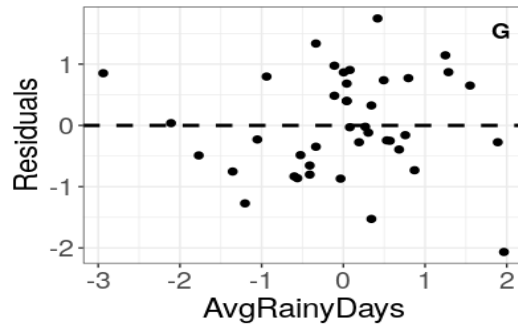
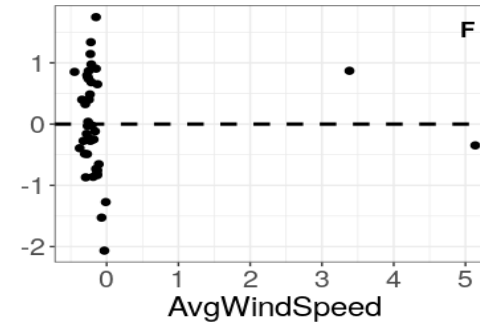
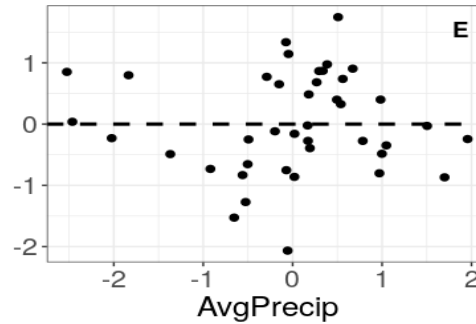

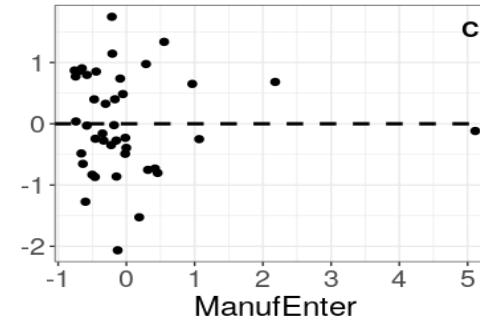


```
DF1s$fit.Q97.5=fit.m2.brms$Q97.5
```

Los gráficos:

Resid vs fitted

Resid vs vars explicativas

QQplot Resid



```
res.fit.m2.brms=ggplot(data=DF1s, aes(x=fit,y=resid))+  
  geom_point(col="black", size=2)+  
  geom_hline(yintercept =0,linetype = 2, size=1.1)+etc  
res.Temp.m2.brms=ggplot(data=DF1s, aes(x=Temp,y=resid))+  
  geom_point(col="black", size=2)+  
  geom_hline(yintercept =0,linetype = 2, size=1.1)+etc
```

THE CODE.

(idem para las otras vars explicativas)

```
qq.m2.brms=ggplot(data=DF1s, mapping=aes(sample = resid)) +  
  stat_qq_point()+ stat_qq_line()+ stat_qq_band(alpha=0.3)+  
  labs(x = "Theoretical Quantiles", y = "Sample Quantiles")+etc
```

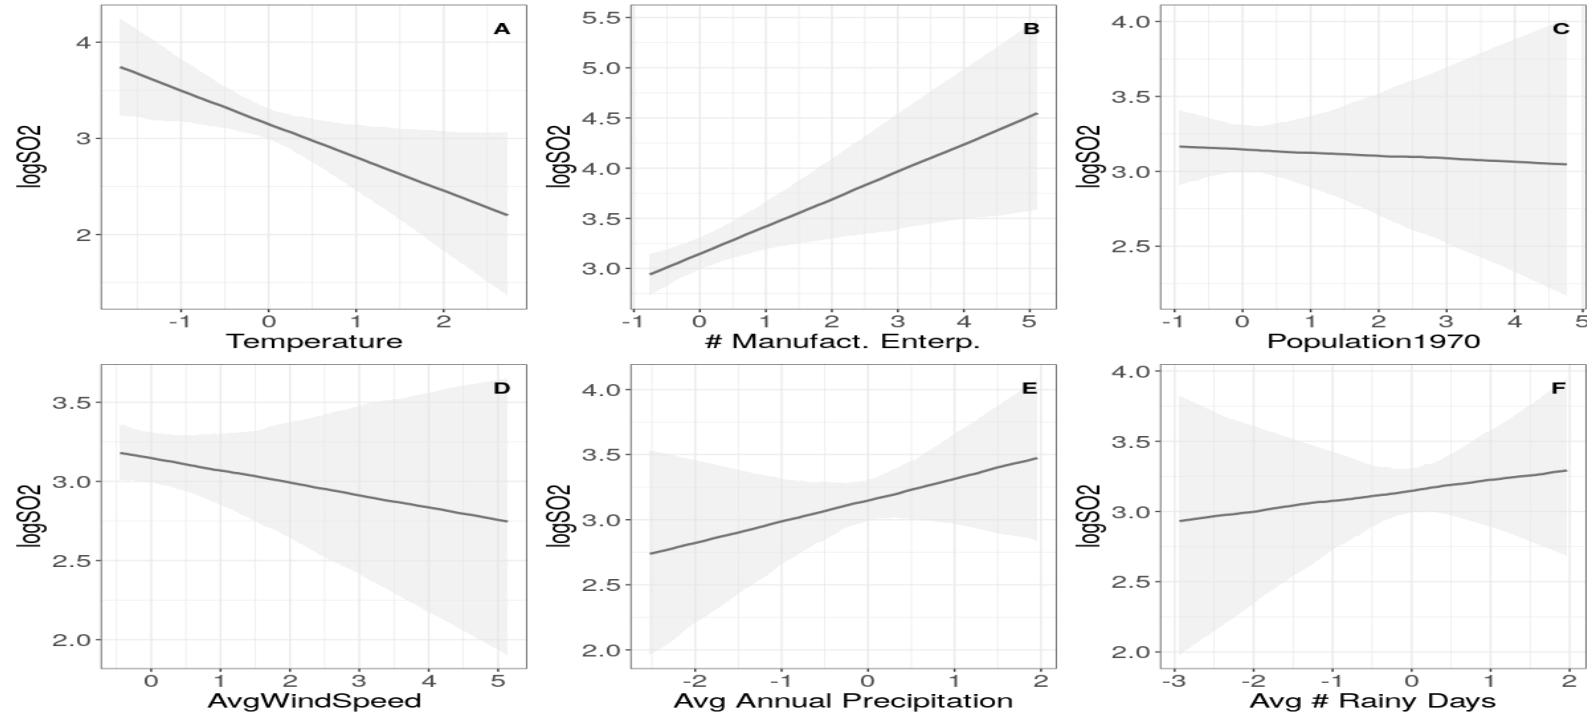
qqplotr

```
plot_grid(res.fit.m2.brms, res.Temp.m2.brms,res.ManufEnter.m2.brms,  
  res.Population1970.m2.brms,res.AvgPrecip.m2.brms,res.AvgWindSpeed.m2.brms,  
  res.AvgRainyDays.m2.brms, qq.m2.brms,ncol=3,labels = LETTERS[1:8],  
  align="hv",label_x=0.90, label_y=0.95)
```

6) Curvas condicionales `m2.brms.cond.eff=conditional_effects(m2.brms)` Relaciones predichas para cada var. explicativa.

```
> names(m2.brms.cond.eff)
```

```
[1] "Temp" "ManufEnter" "Population1970" "AvgWindSpeed" "AvgPrecip"  
[6] "AvgRainyDays"
```



```
ggplot(data=m2.brms.cond.eff$Temp, aes(x=Temp, y=estimate__))+ geom_line(size=1)+  
geom_ribbon(aes(ymin=lower__,ymax=upper__),fill = "grey90", alpha=0.5)+ etc
```

b. Distribuciones previas I:

La gran discusión es cómo moderar la influencia relativa del conocimiento previo y de los aspectos particulares de los datos en los resultados, i.e. en las distr. posteriores.

El mundo NO COMIENZA DE NUEVO con cada análisis como se pretende de “forma objetiva” la estadística frecuentista → dist previas uniformes. (todo es posible)

La estadística bayesiana carece de un procedimiento general para definir las dist previas de clases de modelos.

Hay un inevitable grado de discrecionalidad o arbitrariedad remanente al definir las distr. previas.

Hay **al menos 3 grandes razones** para ello:

- a) No es obvio **decidir qué es un antecedente válido** a la hora de definir las dist. previas de los parámetros.
- b) No es trivial **cómo armonizar/ponderar diferentes fuentes de evidencia** previa de “**expertos**” en un tema.
- c) Dista de ser evidente **cómo transformar evidencia** previa (i.e. media, sd, rangos) **en distr. de probabilidad**.

No obstante, **hay enfoques e ideas recientes** al respecto algunas provenientes de la psicología: O’Hagan (2019), Paoli & van de Shoot (2017), Veen et al (2017) y otros.

Las **dist. previas** podrían ser “demasiado importantes” :

- * cuando hay **pocos datos** para la **complejidad** del modelo a ajustar ← ¿frecuente en ciencias naturales y sociales?

- * cuando los **datos** tienen **gran variabilidad** e “detalles idiosincráticos” en modelos estadísticos complejos.

↳ **Riesgo**: un modelo de buen ajuste, pero no generalizable.

Regularización del modelo: usar las distr. previas para “impedir que el modelo aprenda demasiado de los datos”, una noción bastante difusa y/o metafísica en mi opinión!

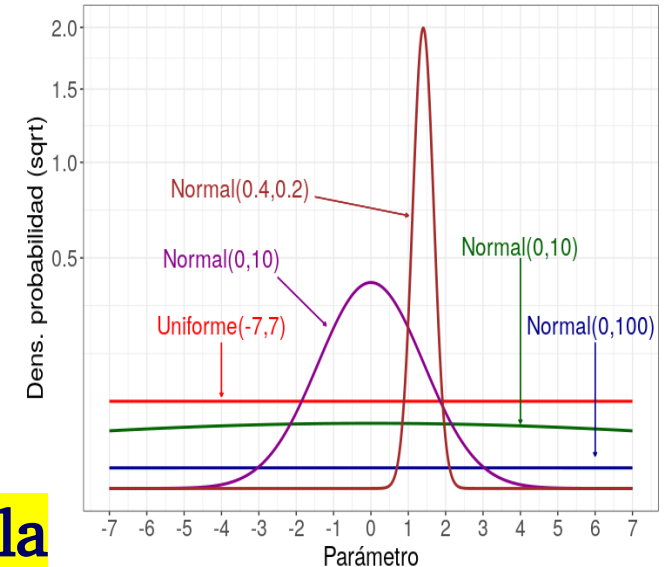
En esta visión, sería aún más importante tener principios claros y defendibles en la definición de las distr. previas...

De forma **MUY general**, se puede categorizar las distr. previas de acuerdo al **grado de información que proveen** sobre los valores plausibles de cada parámetro.

- * **no informativas**: $\sim \text{Uniforme}(\text{min}, \text{max})$ ← “impropias”
- * **vagas**: $\sim \text{Normal}(0, 100)$
- * **débilmente informativas**: $\sim \text{Normal}(0, 10)$
- * **más informativas**: $\sim \text{Normal}(0, 1)$
- * **específica, fuertemente informativas**:
 $\sim \text{Normal}(0.4, 0.2)$ o escaladas.

Ver: van Zwet & Gelman (2021), DePaoli & van de Shoot (2017), Gelman et al (2008), Banner et al (2020), Seaman et al (2011), Lemoine (2019), etc.

Tomar en cuenta **el impacto de la función de enlace** para cada parámetro.



Hay un par de enfoques **no excluyentes** en relación a las distr previas que iremos viendo a lo largo del curso.

1. Análisis de sensibilidad de los resultados a dist. previas con diferente cantidad de información.

Simplemente ajustar el modelo con diferentes dist. previas y evaluar las diferencias entre casos.

2. Prior predictive distribution (Teo 03): permite evaluar los valores de la var de respuesta plausibles según las distr previas (Box 1980, Gabry et al 2019).

Descartar distr previas que generarían valores absurdos o imposibles de la var respuesta.

c. GLM en 6 dispositivas:

Hasta 1972 (y aún en cursos “antediluvianos de estadística”), el análisis de datos casi requería $Y \sim \text{Normal}$

Habían varios métodos de tortura (“transformaciones”) para que $Y \sim \text{Normal}$: $\sin^{-1}(\sqrt{p})$, \log , $\sqrt{y+3/8}$, Box-Cox

En ocasiones, Y claudicaba y $\text{transf}(Y) \sim \text{Normal}$...

Pero en general, estas transformaciones no funcionan:

Warton & Hui 2011, O’Hara & Kotze 2010, Stroup 2014.

Últimas opciones: a) estadística no paramétrica b) tests de aleatorización diseñados para cada problema.

Los Modelos Lineales Generalizados (GLM; Nelder & Wedderburn 1972) permiten analizar distintos tipos de var. respuesta con un único método de estimación de parámetros e inferencia estadística.



	<u>Tipo datos</u>	<u>FuncDesProb</u>	
Y {	Binaria	Binomial	(cada FDensProb tiene su media y otros parám.)
	Conteos	Poisson, Binomial Neg.	
	Proporciones	Beta	
	Reales >0	Gama	
	Reales	Normal (y otras)	



Progresivamente emplearemos éstas (y otras) FDensProb para diferentes tipos de datos.

Table 2.1: Properties of some distributions in the exponential family.

	Poisson	Binomial	Normal	Gamma	Inverse Gaussian	Negative Binomial
$a(\phi)$	1	1	σ^2	ν^{-1}	σ^2	1
$b(\cdot)$	e^θ	$n \log(1 + e^\theta)$	$\theta^2/2$	$-\log(-\theta)$	$-(-2\theta)^{1/2}$	$-\frac{\log(1-e^\theta)}{k}$
$c(y; \phi)$	$-\log y!$	$\log \binom{n}{y}$	$-\frac{1}{2} \left(\frac{y^2}{\phi} + \log(2\pi\phi) \right)$	$\nu \log(\nu y)$ $-\log y - \log \Gamma(\nu)$	$-\frac{1}{2} \log \left(2\pi\phi y^3 + \frac{1}{\phi y} \right)$	
$\mu(\theta) = E(Y; \theta)$	e^θ	$n \cdot e^\theta / (1 + e^\theta)$	θ	$-\frac{1}{\theta}$	$-\frac{1}{\theta^2}$	$-\frac{e^\theta}{(-1+e^\theta)k}$
Canonical link	log	logit	identity	$-\frac{1}{\mu}$	$-\frac{1}{\mu^2}$	$\log \left(\frac{k\mu}{1+k\mu} \right)$
$V(\mu)$	μ	$np(1-p)$	σ^2	μ^2	μ^3	$\mu + k\mu^2$
$Var(y)$	μ	$n\mu(1-\mu)$	σ^2	μ^2/ν	$\sigma^2\mu^3$	$\mu + k\mu^2$

En estadística frecuentista, se formuló un algoritmo (IWLS) para $f(y, \theta, \phi) = \exp\left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi)\right)$ de aplicación general. En estadística bayesiana, se emplea MCMC.

2) El predictor lineal: las var. explicativas X (numéricas y categóricas) predicen $\mu_Y = E(Y) = X\beta$.


Componentes de los GLM:

- 1) Función de probabilidad de Y (random component)
- 2) El predictor lineal de las var.explicativas
- 3) Función de enlace (link function) $g()$

1) Función de probabilidad: se usa una FDensPr que pertenece a la familia exponencial (“modelo generador”).

$$f(y, \theta, \phi) = \exp\left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi)\right)$$

i.e. combinaciones de las funciones a, b y c permiten modelar las diferentes FDensProb como parte de la familia exponencial.



3) La función de enlace (link function) $g()$:

Modela $E(Y) = (X\beta)$ en la escala de $g()$ adecuada a cada tipo de datos. $g(E(Y)) = (X\beta)$

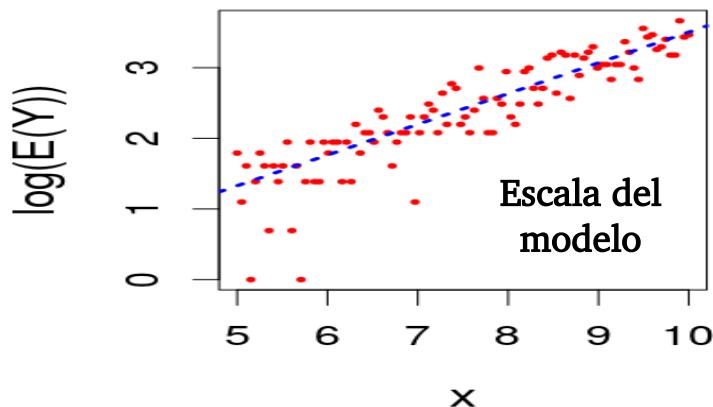
LOS GLM NO TRANSFORMAN Y, sino que modelan la relación $E(Y) = X\beta$ en la escala definida por la función de conexión $g()$ para cada tipo de variable Y.

	<u>Tipo datos</u>	<u>FuncDesProb</u>	<u>Función de enlace $g()$</u>
Y {	Binaria	Binomial	logit, probit
	Conteos	Poisson, Binomial Neg.	log
	Proporciones	Beta	logit
	Reales >0	Gama	inverso, log
	Reales	Normal (y otras)	Identidad, log

Ej: se relacionan conteos (Y) con una var. explicativa numérica $X \rightarrow$ regresión Poisson. Se emplea $g() = \log$.

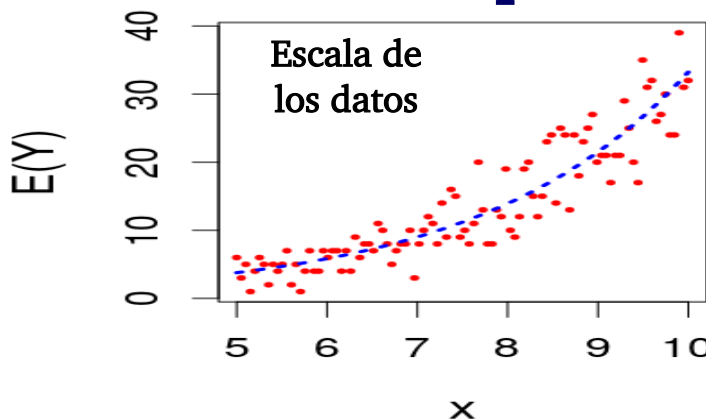
$$\log(E(Y)) = b_0 + b_1 X$$

$$\log(E(Y)) = -0.98 + 0.45X$$



$$E(Y) = g^{-1}(b_0 + b_1 X)$$

$$E(Y) = \exp(-0.98 + 0.45X)$$



$E(Y)$ es una función lineal de la var. explicativas X **únicamente** en la escala de la función de enlace.

En este curso veremos algunas de las distr. de probab. empleadas para modelar diferentes clases de vars. de respuesta, sin llegar a examinarlas todas.

Binaria	Binomial
Conteos	Poisson, Binomial Neg. y modelos de mezcla
Proporciones	Beta
Reales >0	Gama, Lognormal (y modelos de mezcla)
Reales	Normal

`stancode(m2.brms)`

El objetivo es entender los principios del ajuste y la interpretación de resultados de los modelos estadísticos desde la perspectiva bayesiana.

Cada modelo depende de las vars explicativas y sus eventuales interacciones que se desprenden de las hipótesis o del análisis exploratorio de los datos.

Tres ejemplos:

- a. Y: conteos \sim Poisson(μ) $\rightarrow g() = \log()$. X: numérica y si una relación cuadrática: $\log(E(Y)) = \beta_0 + \beta_1 X + \beta_2 X^2$
- b. Y: binaria \sim Binomial(π) $\rightarrow g() = \text{logit}()$. X_1 : numérica y X_2 : categórica $\rightarrow \text{logit}(E(Y)) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 * X_2$.
- c. Y: Reales >0 , \sim Gama(μ, ϕ) $\rightarrow g() = \log()$. X_1 : categórica y X_2 : categórica $\rightarrow \log(E(Y)) = \beta_0 + \beta_1 X_1 + \beta_2 X_2$.

Hay que definir dist previas para TODOS los parámetros. Algunos parámetros de la FuncDensProb de Y tienen rangos de valores plausibles que deben cumplirse.

Trivialmente, sd o $var > 0$ en Normal y Lognormal, pero ϕ (shape) en NegBinom, Beta y Gama también deben ser > 0 , y obviamente $-1 \leq corr \leq 1$.

Las funciones de enlaces de cada parámetro permiten/deben garantizar estas consistencias.

Sin embargo, los valores de los **hiper-parámetros** deben también ser “razonables y consistentes”...



2. Elementos básicos del análisis bayesiano

Teórico 02

- a. Modelo Lineal General: regresión múltiple.
- b. Distribuciones previas I:
- c. GLM en 6 dispositivas.

REFERENCIAS DE ESTA CLASE:

- Banner et al (2020) *Methods in Ecology and Evolution* 11:882-889.
- Box (1980) *Journal of the Royal Statistical Society A* 143: 383-430
- DePaoli & van de Shoot (2017) *Psychological Methods* 22: 240 –261
- Gabry et al (2019) *Journal of the Royal Statistical Society A* 182:389-402
- Gelman et al (2008) *Annals of Statistics* 2: 1360-1383
- Gelman et al (2017) *Entropy* 19: 555-568
- Gelman et al (2018) *American Statistician* 73: 307-309
- Lemoine (2019) *Oikos* 128: 912–928
- O'Hara & Kotze (2010) *Methods in Ecology and Evolution* 1: 118-122
- Seaman et al (2011) *American Statistician* 65:77-84
- Stroup (2014) *Agronomy Journal* 106:1-17
- Warton & Hui (2011) *Ecology* 92:3-10.
- van Zwet & Gelman (2021) *American Statistician* (in press)
- van de Shoot & DePaoli (2014) *European Journal of Health Psychology* 16:76-85